

**סיכום שיעור - משפט בייס**  
**Bayes Theorem Lesson Summary**

ד"ר יורם סגל

© Dr. Yoram Segal - כל הזכויות שמורות

28-11-2025

גרסה 1.0

## תוכן העניינים

3	.....	Zoom Meeting - November 27	1
3	.....	Machine Learning Algorithms Recap	2
3	.....	Introduction to Bayes' Theorem	3
3	.....	Explaining the Bayes' Theorem Formula	4
3	.....	Prior Probability	4.1
3	.....	Likelihood	4.2
4	.....	Posterior Probability	4.3
4	.....	Applying Bayes' Theorem for Classification	5
4	.....	Independence Assumption	5.1
4	.....	Covariance Matrix	5.2
	.....	Handling High-Dimensional	6
4	.....	Feature Spaces	
4	.....	Naive Bayes Solution	6.1
4	.....	Dimensionality Reduction	6.2
5	.....	Recap and Next Steps	7
5	.....	Upcoming Assignment	7.1

## 1 פגישת זום - 27 בנובמבר: Zoom Meeting - November 27

פגישת זום שנערכה ב-27 בנובמבר סקרה את הנושאים המרכזיים בלמידת מכונה ומשפט בייס.

## 2 סקירת אלגוריתמי למידת מכונה: Machine Learning Algorithms Recap

הכיתה סקרה את אלגוריתמי למידת המכונה שנלמדו עד כה, כולל:

- רגרסיה ליניארית (Linear Regression)

- רגרסיה לוגיסטית (Logistic Regression)

- K השכנים הקרובים ביותר (K-Nearest Neighbors - KNN)

- אשכול K-ממוצעים (K-Means Clustering)

- ניתוח רכיבים ראשיים (Principal Component Analysis - PCA)

ההבדל המרכזי שהודגש הוא ש-PCA מתמקד במקסום השונות הכללית בנתונים, בעוד ש-Linear Discriminant Analysis (LDA) שואף למקסם את ההפרדה בין המחלקות.

## 3 מבוא למשפט בייס: Introduction to Bayes' Theorem

המרצה הציג את משפט בייס (Bayes' Theorem), המספק דרך לחשב את ההסתברות המותנית של אירוע בהינתן ידע מוקדם על התנאים שעשויים להיות רלוונטיים. משפט בייס שימושי במיוחד לבעיות סיווג שבהן אנחנו רוצים לקבוע את ההסתברות שתצפית שייכת למחלקה מסוימת.

## 4 הסבר נוסחת משפט בייס: Explaining the Bayes' Theorem Formula

המרצה עבר על נוסחת משפט בייס בפירוט, והסביר את המשמעות של המרכיבים הבאים:

### 4.1 הסתברות אפריורית: Prior Probability

ההסתברות המוקדמת (Prior Probability) - ההסתברות של אירוע לפני שמתקבל מידע חדש.

### 4.2 נראות: Likelihood

הנראות (Likelihood) - הסבירות לראות את הנתונים בהינתן שהאירוע התרחש.

### 4.3 הסתברות פוסטרירורית: Posterior Probability

ההסתברות הפוסטרירורית (Posterior Probability) - ההסתברות המעודכנת לאחר קבלת מידע חדש.

המרצה הראה כיצד לחשב ערכים אלה באמצעות היסטוגרמות של ערכי המאפיינים עבור כל מחלקה.

## 5 יישום משפט בייס לסיווג: Applying Bayes' Theorem for Classification

המרצה הדגים כיצד ליישם את משפט בייס לסיווג תצפית חדשה:

1. חישוב ההסתברות הפוסטרירורית עבור כל מחלקה

2. בחירת המחלקה עם ההסתברות הגבוהה ביותר

### 5.1 הנחת האי-תלות: Independence Assumption

הודגשה חשיבות הנחת האי-תלות ב-Naive Bayes. הנחה זו מניחה שהמאפיינים בלתי תלויים זה בזה בהינתן המחלקה.

### 5.2 מטריצת השונות המשותפת: Covariance Matrix

ניתן להרפות את הנחת האי-תלות באמצעות טכניקות כמו מטריצת השונות המשותפת (Covariance Matrix), המאפשרת לתאר קשרים בין המאפיינים.

## 6 התמודדות עם מרחבי מאפיינים רב-ממדיים: Handling High-Dimensional Feature Spaces

המרצה דן באתגר של מרחבי מאפיינים רב-ממדיים, שבהם מספר השילובים האפשריים של ערכי מאפיינים גדל באופן אקספוננציאלי.

### 6.1 הפתרון באמצעות Naive Bayes: Naive Bayes Solution

הנחת האי-תלות ב-Naive Bayes מסייעת להתמודד עם בעיה זו על ידי הפיכת החישוב לבר-ביצוע (tractable).

במקום לחשב הסתברויות משותפות על פני כל צירופי המאפיינים, ניתן לחשב הסתברויות לכל מאפיין בנפרד ולהכפיל אותן.

### 6.2 הפחתת ממדיות: Dimensionality Reduction

ניתן להשתמש גם בטכניקות של הפחתת ממדיות (Dimensionality Reduction) כמו PCA לפני הפעלת אלגוריתם הסיווג.

## 7 סיכום ושלבים הבאים: Recap and Next Steps

המרצה סיכם את המושגים המרכזיים שנלמדו בשיעור:

- נוסחת משפט בייס והמרכיבים שלה
- מסווג Naive Bayes והנחת האי-תלות
- טכניקות להתמודדות עם נתונים רב-ממדיים

### 7.1 המטלה הקרובה: Upcoming Assignment

הוסברו ההנחיות למטלה הקרובה, שתכלול יישום של Naive Bayes על מערך הנתונים Iris. מערך הנתונים Iris מכיל 150 דגימות של 3 סוגי פרחי אירוס, עם 4 מאפיינים לכל דגימה:

- אורך עלה הכותרת (Sepal Length)
- רוחב עלה הכותרת (Sepal Width)
- אורך עלה הכותרת הפנימי (Petal Length)
- רוחב עלה הכותרת הפנימי (Petal Width)